

Πανεπιστήμιο Πειραιώς

ΕΚΕΦΕ Δημόκριτος

Μάθημα:

Θεμελιώδεις Γνώσεις για την Τεχνητή Νοημοσύνη

Ανάλυση και Συγκριτική Μελέτη των Μεθόδων PCA και LDA

Ονοματεπώνυμο: Αγάπη Καλλίνικου

Α.Μ.: mtn2609

Χειμερινό Εξάμηνο 2026--2027

Περιεχόμενα

1 Περίληψη **2**

2 Εισαγωγή **2**

3 Θεωρητικό Υπόβαθρο **2**
3.1 Διακύμανση . . . 2
3.2 Συνδιακύμανση . . . 3
3.3 Ιδιοτιμές και Ιδιοδιανύσματα . . . 3
3.4 Διανύσματα Μέσων . . . 3
3.5 Ενδοταξική και μεταξύ των τάξεων διασπορά . . . 4

4 Η μέθοδος PCA **4**
4.1 Μεθοδολογία Εφαρμογής του PCA . . . 4
4.1.1 Οργάνωση των δεδομένων . . . 5
4.1.2 Προεπεξεργασία των δεδομένων . . . 5
4.1.3 Υπολογισμός πίνακα συνδιακύμανσης χαρακτηριστικών . . . 5
4.1.4 Υπολογισμός ιδιοτιμών και ιδιοδιανυσμάτων . . . 5
4.1.5 Προσδιορισμός και επιλογή κύριων συνιστωσών . . . 5
4.1.6 Μετασχηματισμός των δεδομένων . . . 6

5 Η μέθοδος LDA **6**
5.1 Μεθοδολογία Εφαρμογής του LDA . . . 7
5.1.1 Οργάνωση των δεδομένων και των ετικετών . . . 7
5.1.2 Προεπεξεργασία των δεδομένων . . . 7
5.1.3 Υπολογισμός των διανυσμάτων μέσων . . . 7
5.1.4 Υπολογισμός των πινάκων ενδοταξικής και μεταξύ των τάξεων διασποράς . . . 8
5.1.5 Προσδιορισμός των διακριτικών κατευθύνσεων . . . 8
5.1.6 Επιλογή διακριτικών συνιστωσών και μετασχηματισμός των δεδομένων . . . 8

6 Πρακτική Εφαρμογή **8**
6.1 Dataset και επιλογή χαρακτηριστικών . . . 8
6.2 Εφαρμογή της PCA με Python . . . 9
6.2.1 Αποτελέσματα και ερμηνεία . . . 9
6.3 Εφαρμογή της LDA με Python . . . 10
6.3.1 Αποτελέσματα και ερμηνεία . . . 11

7 Συμπεράσματα και σύγκριση μεθόδων **13**

8 Βιβλιογραφία **15**

9 Παράρτημα **16**
9.1 Παράρτημα Α: Εναλλακτική προσέγγιση μέσω SVD . . . 16
9.2 Παράρτημα Β: Κώδικας υλοποίησης PCA σε Python . . . 16
9.3 Παράρτημα Γ: Κώδικας υλοποίησης LDA σε Python . . . 18

1. Περίληψη

Η παρούσα εργασία εξετάζει δύο ευρέως διαδεδομένες γραμμικές μεθόδους μείωσης διαστάσεων, την Ανάλυση Κύριων Συνιστωσών (*Principal Component Analysis - PCA*) και τη Γραμμική Διακριτική Ανάλυση (*Linear Discriminant Analysis - LDA*). Αρχικά, παρουσιάζονται οι βασικές θεωρητικές έννοιες, ενώ ακολουθεί η ανάλυση των διαδοχικών βημάτων εφαρμογής της κάθε μεθόδου. Έπειτα, για την πρακτική εφαρμογή τους, οι δύο μέθοδοι εφαρμόζονται στο σύνολο δεδομένων *Breast Cancer Wisconsin (Diagnostic)*, το οποίο περιλαμβάνει χαρακτηριστικά όγκων που χρησιμοποιούνται για τη διάκριση καλοήθων και κακοήθων περιπτώσεων. Μέσω της υλοποίησης σε Python, μελετάται η δυνατότητα μείωσης των διαστάσεων, η διατήρηση της πληροφορίας και ο διαχωρισμός των κατηγοριών. Επιπρόσθετα, εξετάζεται η χρήση της LDA ως ταξινομητή. Τέλος, οι δύο μέθοδοι συγκρίνονται ως προς τις δυνατότητες, τους περιορισμούς και τα πεδία εφαρμογής τους.

2. Εισαγωγή

Η ανάλυση δεδομένων αποτελεί βασικό εργαλείο σε ευρύ φάσμα επιστημονικών εφαρμογών. Συνήθως, τα διαθέσιμα σύνολα δεδομένων περιλαμβάνουν μεγάλο αριθμό χαρακτηριστικών, γεγονός που δυσχεραίνει την ερμηνεία τους και αυξάνει την υπολογιστική πολυπλοκότητα της ανάλυσης. Για τον λόγο αυτό, χρησιμοποιούνται μέθοδοι μείωσης διαστάσεων, οι οποίες αναπαραστούν τα δεδομένα σε χώρο μικρότερης διάστασης ενώ, ταυτόχρονα, περιορίζουν την απώλεια πληροφορίας.

Σκοπός της παρούσας εργασίας είναι η μελέτη και η συγκριτική παρουσίαση δύο ευρέως χρησιμοποιούμενων τέτοιων μεθόδων: της Ανάλυσης Κύριων Συνιστωσών (*Principal Component Analysis - PCA*) και της Γραμμικής Διακριτικής Ανάλυσης (*Linear Discriminant Analysis - LDA*), οι οποίες διαφέρουν ως προς τον σκοπό τους. Συγκεκριμένα, η PCA εστιάζει στη διατήρηση της συνολικής διακύμανσης, ενώ η LDA αξιοποιεί τις γνωστές κατηγορίες των παρατηρήσεων, στοχεύοντας στον αποτελεσματικότερο διαχωρισμό τους.

3. Θεωρητικό Υπόβαθρο

3.1. Διακύμανση

Η διακύμανση (*variance*) αποτελεί βασικό μέτρο της στατιστικής, το οποίο περιγράφει τον βαθμό διασποράς των τιμών μιας μεταβλητής γύρω από τη μέση τιμή της. Για μια τυχαία μεταβλητή X, με μέση τιμή $\mu = \mathbb{E}[X]$, η διακύμανση ορίζεται ως η αναμενόμενη τιμή του τετραγώνου της απόκλισης της μεταβλητής από τη μέση τιμή της:

$$\mathrm{Var}(X) = \mathbb{E}\left[(X - \mu)^2\right].$$

Για ένα σύνολο n παρατηρήσεων $x_1, x_2, \ldots, x_n$, η διακύμανση μπορεί να υπολογιστεί ως:

$$\sigma^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2,$$

όπου $\bar{x}$ είναι ο αριθμητικός μέσος των παρατηρήσεων. Σε περίπτωση που οι παρατηρήσεις αποτελούν τυχαίο δείγμα και χρειάζεται η αμερόληπτη εκτίμηση της πληθυσμιακής διακύμανσης, χρησιμοποιείται ο παρονομαστής $n - 1$.

Η διακύμανση είναι πάντοτε μη αρνητική και ισούται με μηδέν όταν όλες οι παρατηρήσεις έχουν την ίδια τιμή.

3.2. Συνδιακύμανση

Η συνδιακύμανση (*covariance*) περιγράφει τον τρόπο της από κοινού μεταβολής δύο μεταβλητών. Επομένως, ενώ η διακύμανση αναφέρεται στην διασπορά μιας μεταβλητής γύρω από τη μέση τιμή της, η συνδιακύμανση αποτυπώνει τη γραμμική τους σχέση.

Για ένα σύνολο n παρατηρήσεων (x_i, y_i), η συνδιακύμανση υπολογίζεται ως:

$$\text{Cov}(X, Y) = \frac{1}{n} \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y}),$$

όπου $\bar{x}$ και $\bar{y}$ είναι οι αριθμητικοί μέσοι των δύο μεταβλητών. Σε περίπτωση που οι παρατηρήσεις αποτελούν τυχαίο δείγμα και χρειάζεται η αμερόληπτη εκτίμηση της πληθυσμιακής συνδιακύμανσης, χρησιμοποιείται ο παρονομαστής $n - 1$.

Η συνδιακύμανση μπορεί να είναι είτε θετική είτε αρνητική ή μηδενική. Η θετική συνδιακύμανση δηλώνει ότι οι δύο μεταβλητές αποκλίνουν από τις μέσες τιμές τους προς την ίδια κατεύθυνση, ενώ η αρνητική συνδιακύμανση υποδηλώνει ότι αποκλίνουν προς αντίθετες κατευθύνσεις. Ωστόσο, η απουσία (γραμμικής) συνδιακύμανσης δεν δίνει πληροφορία για την ύπαρξη (ή την απουσία) μη γραμμικής σχέσης μεταξύ των μεταβλητών.

3.3. Ιδιοτιμές και Ιδιοδιανύσματα

Έστω ένας τετραγωνικός πίνακας A. Ένα μη μηδενικό διάνυσμα $\mathbf{v}$ ονομάζεται ιδιοδιάνυσμα (eigenvector) του A εάν υπάρχει ένας αριθμός λ τέτοιος ώστε να ισχύει:

$$A\mathbf{v} = \lambda\mathbf{v}, \qquad \mathbf{v} \neq \mathbf{0},$$

όπου λ ονομάζεται ιδιοτιμή (eigenvalue) που αντιστοιχεί στο ιδιοδιάνυσμα $\mathbf{v}$. Η σχέση αυτή εξηγεί ότι ο πολλαπλασιασμός του ιδιοδιανύσματος με τον πίνακα A διατηρεί την ίδια διεύθυνση ή την αντιστρέφει.

Επιπλέον, οι ιδιοτιμές προσδιορίζονται συνήθως από τη λύση της χαρακτηριστικής εξίσωσης:

$$\det(A - \lambda I) = 0,$$

όπου I είναι ο μοναδιαίος πίνακας κατάλληλης διάστασης και με det συμβολίζεται η ορίζουσα. Έπειτα, τα αντίστοιχα ιδιοδιανύσματα υπολογίζονται από τη λύση του συστήματος

$$(A - \lambda I)\mathbf{v} = \mathbf{0}.$$

3.4. Διανύσματα Μέσων

Όταν ένα σύνολο δεδομένων περιλαμβάνει πολλά χαρακτηριστικά, οι μέσες τιμές τους εκφράζονται μέσω ενός διανύσματος μέσων. Για ένα σύνολο n παρατηρήσεων με p χαρακτηριστικά, το διάνυσμα μέσων ορίζεται ως:

$$\boldsymbol{\mu} = \frac{1}{n}\sum_{i=1}^{n}\mathbf{x}_i,$$

όπου $\mathbf{x}_i \in \mathbb{R}^p$ είναι το διάνυσμα χαρακτηριστικών της i-οστής παρατήρησης. Όταν τα δεδομένα χωρίζονται σε κατηγορίες, υπολογίζεται αντίστοιχο διάνυσμα μέσων για κάθε κατηγορία, αλλά και ένα συνολικό, για ολόκληρο το σύνολο δεδομένων.

3.5. Ενδοταξική και μεταξύ των τάξεων διασπορά

Η *ενδοταξική διασπορά* περιγράφει πόσο διαφέρουν τα δείγματα που ανήκουν στην ίδια κατηγορία και εκφράζεται από τον πίνακα:

$$S_W = \sum_{k=1}^{K}\sum_{\mathbf{x}_i \in C_k}(\mathbf{x}_i - \boldsymbol{\mu}_k)(\mathbf{x}_i - \boldsymbol{\mu}_k)^T,$$

ενώ η *μεταξύ των τάξεων διασπορά* αποτυπώνει το πόσο διαφέρουν οι κατηγορίες μεταξύ τους, με βάση τους αντίστοιχους μέσους όρους τους, και εκφράζεται από τον πίνακα:

$$S_B = \sum_{k=1}^{K} n_k(\boldsymbol{\mu}_k - \boldsymbol{\mu})(\boldsymbol{\mu}_k - \boldsymbol{\mu})^T.$$

Στους παραπάνω τύπους, k είναι ο αριθμός των κατηγοριών, C_k το σύνολο των παρατηρήσεων της k-οστής κατηγορίας, n_k το πλήθος των παρατηρήσεών της, $\boldsymbol{\mu}_k$ το διάνυσμα μέσων της κατηγορίας και $\boldsymbol{\mu}$ το συνολικό διάνυσμα μέσων.

4. Η μέθοδος PCA

Η Ανάλυση Κύριων Συνιστωσών (*Principal Component Analysis - PCA*) είναι μια γραμμική μέθοδος, η οποία καταφέρνει να μειώσει τη διάσταση των δεδομένων μετασχηματίζοντας τα αρχικά χαρακτηριστικά σε ένα νέο σύνολο ασυσχέτιστων μεταβλητών, οι οποίες ονομάζονται κύριες συνιστώσες. Στόχος είναι η διατήρηση όσο το δυνατόν μεγαλύτερου μέρους της συνολικής διακύμανσης των δεδομένων, με χρήση όμως μικρότερου αριθμού διαστάσεων. Η μέθοδος είναι ιδιαίτερα χρήσιμη όταν τα δεδομένα περιλαμβάνουν πολλά χαρακτηριστικά, ειδικά αν παρουσιάζουν συσχετίσεις μεταξύ τους.

Η PCA αξιοποιείται για την οπτικοποίηση πολυδιάστατων δεδομένων σε λιγότερες διαστάσεις, τον περιορισμό υπερβολικής ποσότητας πληροφορίας και τη συμπίεση δεδομένων. Ωστόσο, η διατήρηση της μέγιστης δυνατής διακύμανσης δεν εγγυάται τη διατήρηση της πληροφορίας που είναι σημαντικότερη για την ταξινόμηση, καθώς, αφού δεν χρησιμοποιούνται οι ετικέτες των κλάσεων, ενδέχεται να απορριφθούν χρήσιμες κατευθύνσεις που έχουν, όμως, μικρή διακύμανση. Επιπλέον, ως γραμμική μέθοδος, δεν αποτυπώνει απαραίτητα τις μη γραμμικές σχέσεις εμταξύ των δεδομένων. Τέλος, όταν τα χαρακτηριστικά έχουν διαφορετικές κλίμακες ή μονάδες μέτρησης, ενδείκνυται τυποποίηση πριν από την εφαρμογή της μεθόδου, ώστε χαρακτηριστικά με μεγάλες αριθμητικές τιμές να μην κυριαρχούν στο αποτέλεσμα.

4.1. Μεθοδολογία Εφαρμογής του PCA

4.1.1. Οργάνωση των δεδομένων. Τα δεδομένα οργανώνονται σε έναν πίνακα

$$X \in \mathbb{R}^{n \times p},$$

όπου n είναι ο αριθμός των παρατηρήσεων και p ο αριθμός των χαρακτηριστικών. Κάθε γραμμή αντιστοιχεί σε μία παρατήρηση και κάθε στήλη σε ένα χαρακτηριστικό. Πριν από την εφαρμογή της PCA, ελέγχεται η ποιότητα των δεδομένων και αντιμετωπίζονται τυχόν ελλείπουσες τιμές ή ασυνέπειες.

4.1.2. Προεπεξεργασία των δεδομένων. Αρχικά, τα δεδομένα κεντράρονται με αφαίρεση του μέσου όρου κάθε χαρακτηριστικού. Για την τιμή x_{ij} του χαρακτηριστικού j στην παρατήρηση i, ισχύει:

$$x_{ij}^{(c)} = x_{ij} - \bar{x}_j,$$

όπου $\bar{x}_j$ είναι ο μέσος όρος του j-οστού χαρακτηριστικού. Έτσι, κάθε χαρακτηριστικό αποκτά μέσο όρο μηδέν.

Όταν τα χαρακτηριστικά έχουν διαφορετικές μονάδες μέτρησης ή διαφορετικές κλίμακες, εφαρμόζεται τυποποίηση, διαιρώντας τις κεντραρισμένες τιμές με την αντίστοιχη τυπική απόκλιση. Η επιλογή εξαρτάται από τη φύση των δεδομένων και τον σκοπό της ανάλυσης.

4.1.3. Υπολογισμός πίνακα συνδιακύμανσης χαρακτηριστικών. Αν X_c ο πίνακας των κεντραρισμένων δεδομένων, ο πίνακας συνδιακύμανσης ορίζεται ως:

$$S = \frac{1}{n-1} X_c^T X_c.$$

Ο πίνακας $S \in \mathbb{R}^{p \times p}$ περιέχει στις διαγώνιες θέσεις τις διακυμάνσεις των χαρακτηριστικών και στις υπόλοιπες τις συνδιακυμάνσεις μεταξύ τους. Όταν έχει προηγηθεί τυποποίηση, μπορεί ισοδύναμα να χρησιμοποιηθεί ο πίνακας συσχέτισης των αρχικών χαρακτηριστικών. Η επιλογή αυτή επηρεάζει τις κύριες συνιστώσες που προκύπτουν.

4.1.4. Υπολογισμός ιδιοτιμών και ιδιοδιανυσμάτων. Οι ιδιοτιμές και τα ιδιοδιανύσματα του πίνακα συνδιακύμανσης S υπολογίζονται μέσω της σχέσης:

$$Sv_j = \lambda_j v_j.$$

Οι ιδιοτιμές λ_j εκφράζουν τη διακύμανση κατά μήκος των αντίστοιχων κύριων διευθύνσεων, ενώ τα ιδιοδιανύσματα v_j καθορίζουν τις διευθύνσεις αυτές στον αρχικό χώρο των χαρακτηριστικών. Επειδή ο πίνακας συνδιακύμανσης είναι συμμετρικός και θετικά ημιορισμένος, οι ιδιοτιμές του είναι μη αρνητικές και τα ιδιοδιανύσματα μπορούν να επιλεγούν ορθοκανονικά.

4.1.5. Προσδιορισμός και επιλογή κύριων συνιστωσών. Οι ιδιοτιμές ταξινομούνται κατά φθίνουσα σειρά,

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p \geq 0,$$

και τα αντίστοιχα ιδιοδιανύσματα ακολουθούν την ίδια σειρά. Η πρώτη κύρια συνιστώσα αντιστοιχεί στην κατεύθυνση μέγιστης διακύμανσης των προβολών των δεδομένων. Κάθε επόμενη συνιστώσα είναι ορθογώνια προς τις προηγούμενες και μεγιστοποιεί τη διακύμανση στην αντίστοιχη κατεύθυνση.

Για σύνολο δεδομένων με p χαρακτηριστικά, η j-οστή κύρια συνιστώσα ορίζεται ως γραμμικός συνδυασμός των κεντραρισμένων χαρακτηριστικών:

$$PC_j = \sum_{i=1}^{p} v_{ij}(X_i - \bar{X}_i),$$

όπου X_i είναι η τιμή του i-οστού χαρακτηριστικού, $\bar{X}_i$ η μέση τιμή του και v_{ij} η i-οστή συνιστώσα του ιδιοδιανύσματος που αντιστοιχεί στην j-οστή κύρια συνιστώσα. Επομένως, κάθε παρατήρηση αναπαρίσταται με νέες συντεταγμένες ως προς τις κύριες συνιστώσες. Σε περίπτωση που έχει προηγηθεί τυποποίηση, ο υπολογισμός γίνεται με τις τυποποιημένες τιμές των χαρακτηριστικών.

Η συνεισφορά κάθε κύριας συνιστώσας στη συνολική διακύμανση εκφράζεται μέσω του ποσοστού εξηγούμενης διακύμανσης:

$$EVR_j = \frac{\lambda_j}{\sum_{i=1}^{p} \lambda_i}.$$

Αν διατηρηθούν οι πρώτες k κύριες συνιστώσες, η αθροιστική εξηγούμενη διακύμανση υπολογίζεται ως:

$$EVR_{1:k} = \frac{\sum_{j=1}^{k} \lambda_j}{\sum_{i=1}^{p} \lambda_i}.$$

Το ποσοστό αυτό αποτελεί και κριτήριο αξιολόγησης της αναπαράστασης. Η μείωση της διάστασης επιτυγχάνεται επιλέγοντας μόνο τις πρώτες k κύριες συνιστώσες, με k < p. Η αθροιστική εξηγούμενη διακύμανση δείχνει το ποσοστό της συνολικής διακύμανσης που διατηρείται και καθορίζει την επιλογή του k, ανάλογα με τον επιθυμητό συμβιβασμό μεταξύ μείωσης των διαστάσεων και διατήρησης της πληροφορίας.

4.1.6. Μετασχηματισμός των δεδομένων. Τέλος, αν V_k είναι ο πίνακας που περιέχει τα k πρώτα ταξινομημένα ιδιοδιανύσματα, ο μετασχηματισμός δίνεται από τη σχέση:

$$Z = X_c V_k,$$

όπου X_c είναι ο πίνακας των κεντραρισμένων δεδομένων και $Z \in \mathbb{R}^{n \times k}$ ο πίνακας των νέων συντεταγμένων των παρατηρήσεων ως προς τις επιλεγμένες κύριες συνιστώσες.

Συνεπώς, κάθε παρατήρηση περιγράφεται πλέον μέσω των k επιλεγμένων κύριων συνιστωσών αντί των p αρχικών χαρακτηριστικών. Για $k < p$, επιτυγχάνεται μείωση των διαστάσεων, διατηρώντας ταυτόχρονα το ποσοστό διακύμανσης που αντιστοιχεί στις επιλεγμένες συνιστώσες.

5. Η μέθοδος LDA

Η Γραμμική Διακριτική Ανάλυση (Linear Discriminant Analysis - LDA) είναι μια γραμμική μέθοδος, η οποία χρησιμοποιείται για τον εντοπισμό ενός μετασχηματισμού των δεδομένων που μεγιστοποιεί τον διαχωρισμό μεταξύ των κατηγοριών και ταυτόχρονα περιορίζει

τη διασπορά των δειγμάτων στο εσωτερικό κάθε κατηγορίας. Έτσι, επιτυγχάνεται η μείωση της διάστασης των δεδομένων και η ταξινόμησή τους σε προκαθορισμένες κατηγορίες. Αντίθετα με την PCA, η οποία βασίζεται στη συνολική διακύμανση των δεδομένων, η LDA βασίζεται στον διαχωρισμό των κατηγοριών βάση των ετικετών τους.

Ωστόσο, η αποτελεσματικότητα της μεθόδου εξαρτάται από το κατά πόσο οι κατηγορίες μπορούν να διαχωριστούν επαρκώς με γραμμικό τρόπο. Επιπλέον, ο μέγιστος αριθμός διακριτικών συνιστωσών που μπορούν να προκύψουν είναι ίσος με $k-1$, όπου k είναι ο αριθμός των κατηγοριών. Επομένως, στην περίπτωση δύο κατηγοριών, όπως στην πρακτική εφαρμογή που περιλαμβάνεται στην παρούσα εργασία, προκύπτει το πολύ μία διακριτική συνιστώσα.

5.1. Μεθοδολογία Εφαρμογής του LDA

5.1.1. Οργάνωση των δεδομένων και των ετικετών. Αρχικά, τα δεδομένα οργανώνονται σε έναν πίνακα χαρακτηριστικών $X \in \mathbb{R}^{n \times p}$, όπου n είναι ο αριθμός των παρατηρήσεων και p ο αριθμός των χαρακτηριστικών. Κάθε γραμμή του πίνακα αντιστοιχεί σε μία παρατήρηση και κάθε στήλη σε ένα χαρακτηριστικό. Ταυτόχρονα, ορίζεται ένα διάνυσμα ετικετών $\mathbf{y} = (y_1, y_2, \ldots, y_n)^T$ που αντιστοιχίζει κάθε παρατήρηση σε μία από τις k κατηγορίες. Οι ετικέτες είναι απαραίτητες για την εφαρμογή της LDA, καθώς η μέθοδος αξιοποιεί την ετικέτα κάθε παρατήρησης προκειμένου να εντοπίσει κατευθύνσεις που διαχωρίζουν όσο το δυνατόν καλύτερα τις κατηγορίες.

5.1.2. Προεπεξεργασία των δεδομένων. Κάθε φορά είναι ιδιαίτερα σημαντικό να δίνεται προσοχή στην αντιμετώπιση πιθανών ελλειπουσών τιμών και στην τυποποίηση. Τυποποίηση εφαρμόζεται όταν τα χαρακτηριστικά έχουν διαφορετικές κλίμακες μέτρησης, ώστε να αποφεύγεται η δυσανάλογη επίδραση χαρακτηριστικών με μεγάλες αριθμητικές τιμές. Για κάθε χαρακτηριστικό j, η τυποποίηση πραγματοποιείται σύμφωνα με τη σχέση:

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j},$$

όπου $\bar{x}_j$ και s_j είναι η μέση τιμή και η τυπική απόκλιση του χαρακτηριστικού j, αντίστοιχα. Η ανάγκη τυποποίησης εξαρτάται από τη φύση και τις κλίμακες των δεδομένων. Σε περίπτωση χρήσης της LDA σε προβλήματα ταξινόμησης, οι παράμετροι της προεπεξεργασίας υπολογίζονται αποκλειστικά από τα δεδομένα εκπαίδευσης, ώστε να αποφεύγεται η διαρροή πληροφορίας από τα δεδομένα ελέγχου.

5.1.3. Υπολογισμός των διανυσμάτων μέσων. Το διάνυσμα μέσων για κάθε κατηγορία περιγράφει το κέντρο των παρατηρήσεων της συγκεκριμένης κατηγορίας στον χώρο των χαρακτηριστικών. Για την k-οστή κατηγορία, το διάνυσμα μέσων δίνεται από τη σχέση:

$$\boldsymbol{\mu}_k = \frac{1}{n_k} \sum_{\mathbf{x}_i \in C_k} \mathbf{x}_i,$$

όπου C_k είναι το σύνολο των παρατηρήσεων της κατηγορίας και n_k το πλήθος τους.

5.1.4. Υπολογισμός των πινάκων ενδοταξικής και μεταξύ των τάξεων διασποράς. Ο πίνακας ενδοταξικής διασποράς S_W αποτυπώνει τη διασπορά των παρατηρήσεων γύρω από το διάνυσμα μέσων της κατηγορίας τους και ορίζεται ως:

$$S_W = \sum_{k=1}^{K} \sum_{\mathbf{x}_i \in C_k} (\mathbf{x}_i - \boldsymbol{\mu}_k)(\mathbf{x}_i - \boldsymbol{\mu}_k)^T.$$

Αντίστοιχα, ο πίνακας μεταξύ των τάξεων διασποράς S_B περιγράφει τη διαφοροποίηση των κατηγοριών με βάση τα διανύσματα μέσων τους και ορίζεται ως:

$$S_B = \sum_{k=1}^{K} n_k(\boldsymbol{\mu}_k - \boldsymbol{\mu})(\boldsymbol{\mu}_k - \boldsymbol{\mu})^T,$$

Στόχος της LDA είναι να εντοπίσει κατευθύνσεις στις οποίες η μεταξύ των τάξεων διασπορά είναι μεγάλη σε σχέση με την ενδοταξική διασπορά, ώστε οι κατηγορίες να διαχωρίζονται όσο το δυνατόν καλύτερα.

5.1.5. Προσδιορισμός των διακριτικών κατευθύνσεων. Οι διακριτικές κατευθύνσεις είναι οι κατευθύνσεις προβολής που επιτυγχάνουν τον καλύτερο δυνατό διαχωρισμό μεταξύ των κατηγοριών. Η λύση του προβλήματος

$$S_B\mathbf{v} = \lambda S_W\mathbf{v},$$

καταλήγει στην εύρεση της τιμής της ιδιοτιμής λ και του αντίστοιχου ιδιοδιανύσματος $\mathbf{v}$, το οποίο καθορίζει μία διακριτική κατεύθυνση. Οι ιδιοτιμές ταξινομούνται κατά φθίνουσα σειρά και επιλέγονται τα ιδιοδιανύσματα που αντιστοιχούν στις μεγαλύτερες ιδιοτιμές. Έτσι, δίνεται προτεραιότητα στις κατευθύνσεις που διαχωρίζουν αποτελεσματικότερα τις κατηγορίες.

5.1.6. Επιλογή διακριτικών συνιστωσών και μετασχηματισμός των δεδομένων. Ο μέγιστος αριθμός των διακριτικών συνιστώσεων στις οποίες θα προβληθούν τα δεδομένα είναι $\min(p, k-1)$, όπου p είναι ο αριθμός των αρχικών χαρακτηριστικών και k ο αριθμός των κατηγοριών. Τα επιλεγμένα ιδιοδιανύσματα σχηματίζουν τον πίνακα W, ο οποίος χρησιμοποιείται για τον μετασχηματισμό των δεδομένων:

$$Z = X_c W,$$

όπου X_c είναι ο κεντραρισμένος πίνακας δεδομένων και Z η νέα αναπαράσταση των παρατηρήσεων στον χώρο των διακριτικών συνιστωσών. Έτσι, μειώνεται η διάσταση των δεδομένων ενώ ταυτόχρονα διατηρείται η πληροφορία που συμβάλλει περισσότερο στον διαχωρισμό των κατηγοριών. Η νέα αναπαράσταση μπορεί να αξιοποιηθεί για την οπτικοποίηση των δεδομένων αλλά και για την εκπαίδευση ενός μοντέλου LDA σε ένα πρόβλημα ταξινόμησης.

6. Πρακτική Εφαρμογή

6.1. Dataset και επιλογή χαρακτηριστικών

Στην παρούσα εργασία χρησιμοποιείται το σύνολο δεδομένων Breast Cancer Wisconsin

(Diagnostic), το οποίο είναι διαθέσιμο στο UCI Machine Learning Repository [9]. Το σύνολο περιλαμβάνει 569 δείγματα και 30 αριθμητικά χαρακτηριστικά για κάθε δείγμα, τα οποία προκύπτουν μέσω της ανάλυσης ψηφιοποιημένων εικόνων κυτταρικών πυρήνων που σχετίζονται με όγκους του μαστού. Κάθε δείγμα συνοδεύεται από χαρακτηρισμό του όγκου ως καλοήθη (*Benign*, B) ή κακοήθη (*Malignant*, M).

6.2. Εφαρμογή της PCA με Python

Μέσω της γλώσσας προγραμματισμού Python και της βιβλιοθήκης `scikit-learn`, η μέθοδος PCA εφαρμόζεται στο σύνολο των 569 δειγμάτων και των 30 αριθμητικών χαρακτηριστικών του dataset. Στόχος αποτελεί η μείωση των διαστάσεων και η ανάλυση της πληροφορίας που διατηρείται μετά τον μετασχηματισμό.

Αρχικά, τα χαρακτηριστικά τυποποιούνται, ώστε να βρίσκονται σε συγκρίσιμη κλίμακα. Στη συνέχεια, εφαρμόζεται η PCA, διατηρώντας όλες τις συνιστώσες, και υπολογίζεται το ποσοστό της συνολικής διακύμανσης που εξηγεί κάθε κύρια συνιστώσα, καθώς και η αθροιστική εξηγούμενη διακύμανση. Με βάση τα αποτελέσματα, επιλέγεται ο αριθμός των κύριων συνιστωσών που απαιτούνται για τη διατήρηση τουλάχιστον του 95% της συνολικής διακύμανσης. Τέλος, εφαρμόζεται η PCA με τον επιλεγμένο αριθμό συνιστωσών, ώστε τα δεδομένα να προβληθούν στον χώρο μειωμένων διαστάσεων.

Ο πλήρης κώδικας της υλοποίησης παρατίθεται στο Παράρτημα Β.

6.2.1. Αποτελέσματα και ερμηνεία. Σύμφωνα με τα αποτελέσματα της ανάλυσης, τα 357 από τα 569 δείγματα αντιστοιχούν σε καλοήθεις όγκους (62,7%), ενώ τα 212 σε κακοήθεις (37,3%). Επομένως, το dataset περιέχει περισσότερα δείγματα καλοήθων όγκων, χωρίς ωστόσο να απουσιάζει η κατηγορία των κακοήθων. Τα χαρακτηριστικά αποτελούν τις μεταβλητές εισόδου για την εφαρμογή της PCA, ενώ οι διαγνωστικές ετικέτες χρησιμοποιούνται για τη μετέπειτα οπτικοποίηση και ερμηνεία των αποτελεσμάτων.

Η ανάλυση της εξηγούμενης διακύμανσης επιτρέπει να εκτιμηθεί πόση από τη συνολική διακύμανση των αρχικών χαρακτηριστικών διατηρείται μέσω των κύριων συνιστωσών. Τα αποτελέσματα για τις 10 πρώτες κύριες συνιστώσες παρουσιάζονται στον Πίνακα 1.

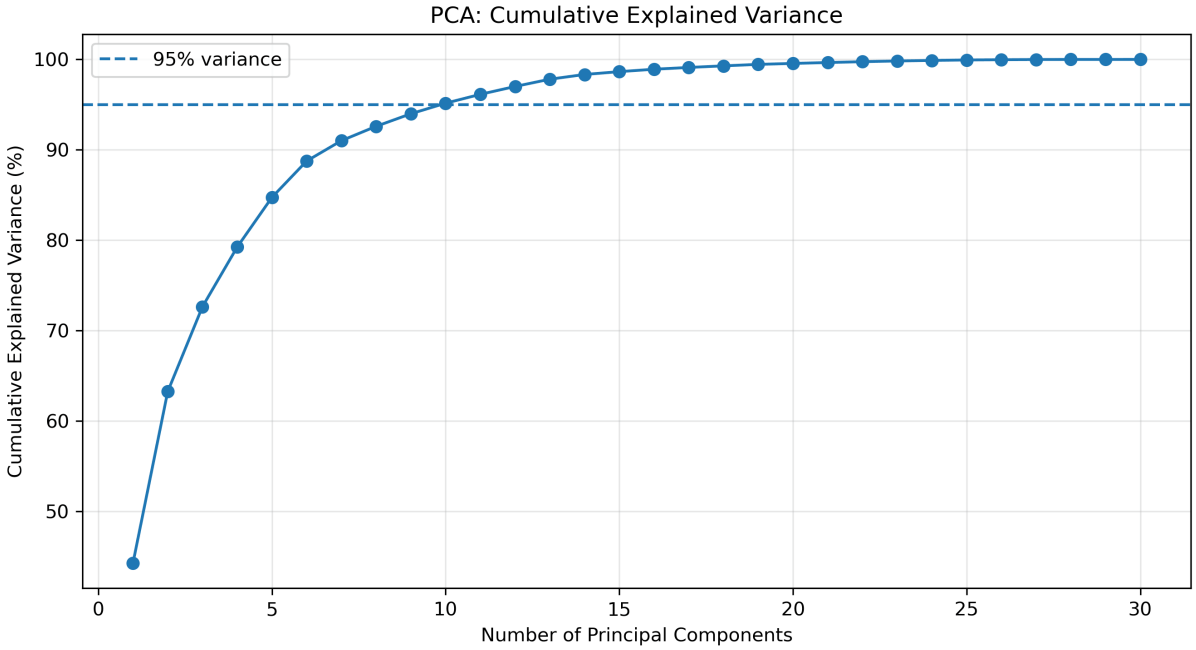
Πίνακας 1: Εξηγούμενη και αθροιστική διακύμανση των πρώτων 10 κύριων συνιστωσών

Κύρια Συνιστώσα	**Εξηγούμενη Διακύμανση (%)**	**Αθροιστική Διακύμανση (%)**
PC1	44.27	44.27
PC2	18.97	63.24
PC3	9.39	72.64
PC4	6.60	79.24
PC5	5.50	84.73
PC6	4.02	88.76
PC7	2.25	91.01
PC8	1.59	92.60
PC9	1.39	93.99
PC10	1.17	95.16

Όπως προκύπτει από τον πίνακα, οι πρώτες κύριες συνιστώσες συγκεντρώνουν ένα σημαντικό μέρος της συνολικής διακύμανσης, καθώς η πρώτη κύρια συνιστώσα εξηγεί το 44,27%, οι δύο πρώτες συνιστώσες εξηγούν αθροιστικά το 63,24% και οι 10 πρώτες,

αντίστοιχα, το 95,16%. Έτσι, επιλέγονται 10 συνιστώσες αντί των 30 αρχικών χαρακτηριστικών, επιτυγχάνοντας μείωση των διαστάσεων κατά 66,7%, με απώλεια περίπου 4,84% της συνολικής διακύμανσης. Το αποτέλεσμα αυτό καταδεικνύει τη δυνατότητα της PCA να αναπαριστά τα δεδομένα σε χώρο μικρότερων διαστάσεων, διατηρώντας μεγάλο μέρος της διακύμανσής τους.

Η αθροιστική εξηγούμενη διακύμανση απεικονίζεται στο Σχήμα 1, όπου και αυξάνεται όσο προστίθενται κύριες συνιστώσες, με την πιο απότομη αύξηση να παρατηρείται στις πρώτες συνιστώσες. Συγκεκριμένα, οι 10 πρώτες συνιστώσες εξηγούν το 95,16% της συνολικής διακύμανσης των αρχικών δεδομένων, ενώ η προσθήκη περισσότερων συνιστωσών προσφέρει όλο και μικρότερο όφελος. Επομένως, η διατήρηση 10 πρώτων συνιστωσών αποτελεί μια αποτελεσματική επιλογή για τη μείωση των διαστάσεων.



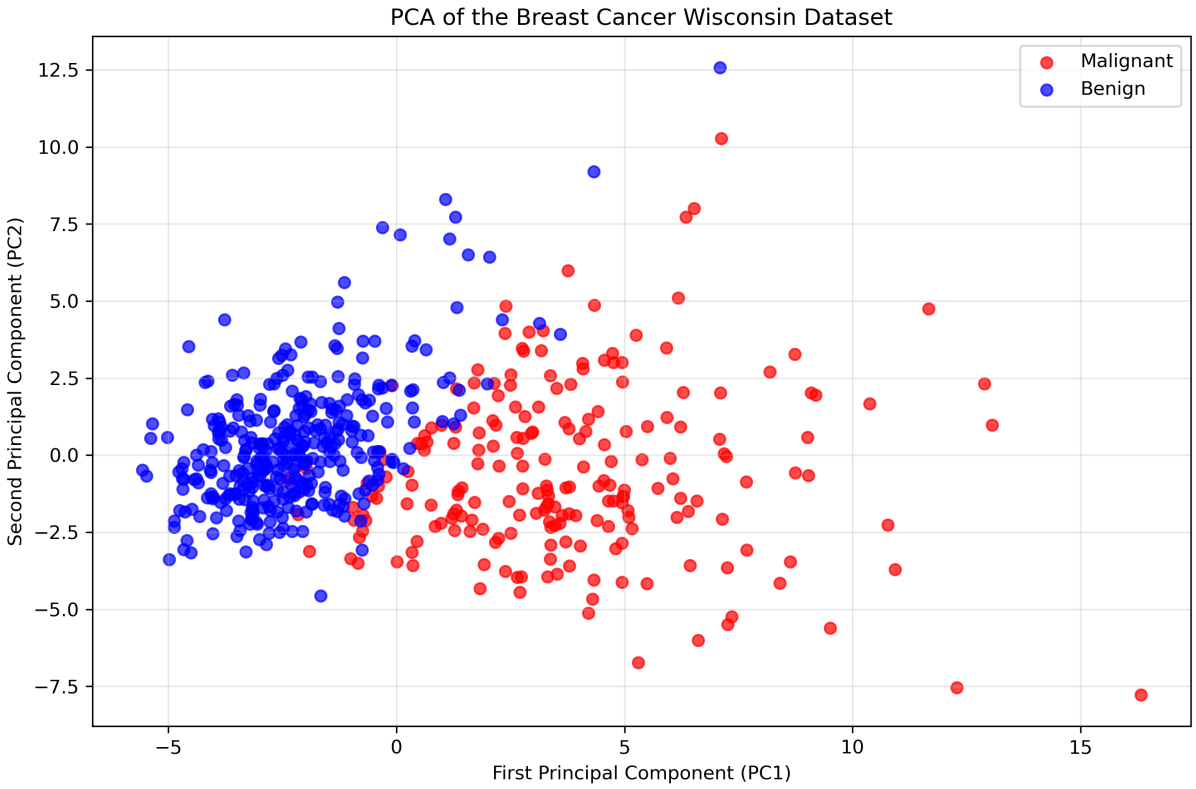
Σχήμα 1: Αθροιστική εξηγούμενη διακύμανση ως προς τον αριθμό των κύριων συνιστωσών.

Στο Σχήμα 2 παρουσιάζεται η προβολή των δειγμάτων στις δύο πρώτες κύριες συνιστώσες, με χρωματισμό ανάλογο της διάγνωσης. Παρατηρείται ότι τα δείγματα καλοήθων όγκων συγκεντρώνονται κυρίως σε αρνητικές τιμές της πρώτης κύριας συνιστώσας, ενώ τα δείγματα κακοήθων όγκων εμφανίζουν μεγαλύτερη διασπορά και τείνουν να επεκτείνονται προς τις θετικές τιμές. Ωστόσο, αν και υπάρχει ένας μικρός διαχωρισμός των δύο κατηγοριών, υπάρχει περιοχή επικάλυψης, γεγονός που δείχνει ότι οι δύο πρώτες κύριες συνιστώσες δεν διαχωρίζουν απόλυτα τα δείγματα βάσει της διάγνωσης.

6.3. Εφαρμογή της LDA με Python

Μέσω της γλώσσας προγραμματισμού Python και της βιβλιοθήκης `scikit-learn`, η μέθοδος LDA εφαρμόζεται στο σύνολο των 569 δειγμάτων και των 30 αριθμητικών χαρακτηριστικών του dataset, με στόχο τη μείωση των διαστάσεων και τον διαχωρισμό των δύο κατηγοριών διάγνωσης όγκων.

Αρχικά, τα χαρακτηριστικά τυποποιούνται και εφαρμόζεται η LDA, με αποτέλεσμα την προβολή των δεδομένων σε μία διακριτική συνιστώσα. Η κατανομή των δειγμάτων στη νέα



Σχήμα 2: Προβολή των δειγμάτων στις δύο πρώτες κύριες συνιστώσες (PC1 και PC2), με χρωματική διάκριση βάσει της διάγνωσης.

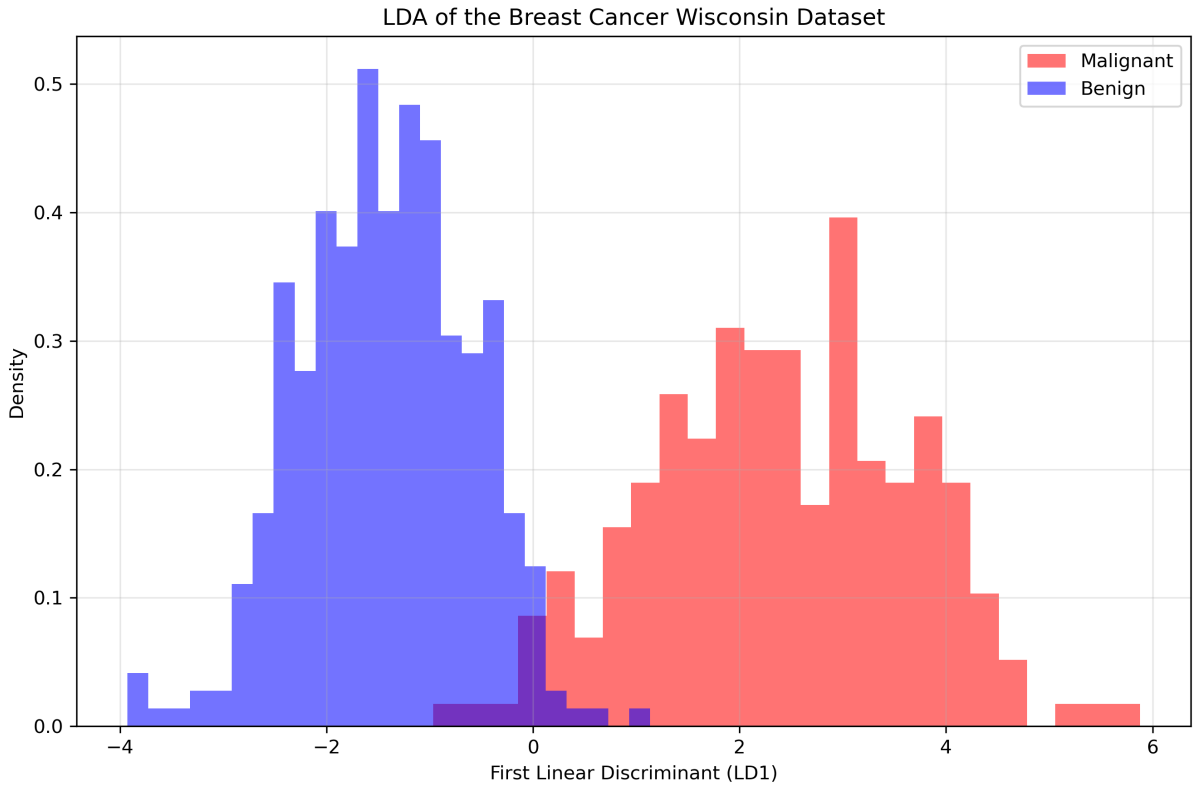
διάσταση απεικονίζεται με ιστογράμματα και διάγραμμα διασποράς, ώστε να εξεταστεί ο βαθμός διαχωρισμού των δύο κατηγοριών. Επιπλέον, η μέθοδος αξιολογείται και ως ταξινομητής σε συγκεκριμένο σύνολο δεδομένων ελέγχου, με χρήση διάφορων μετρικών και οπτικοποίηση πίνακα σύγχυσης.

Ο πλήρης κώδικας της υλοποίησης παρατίθεται στο Παράρτημα Γ.

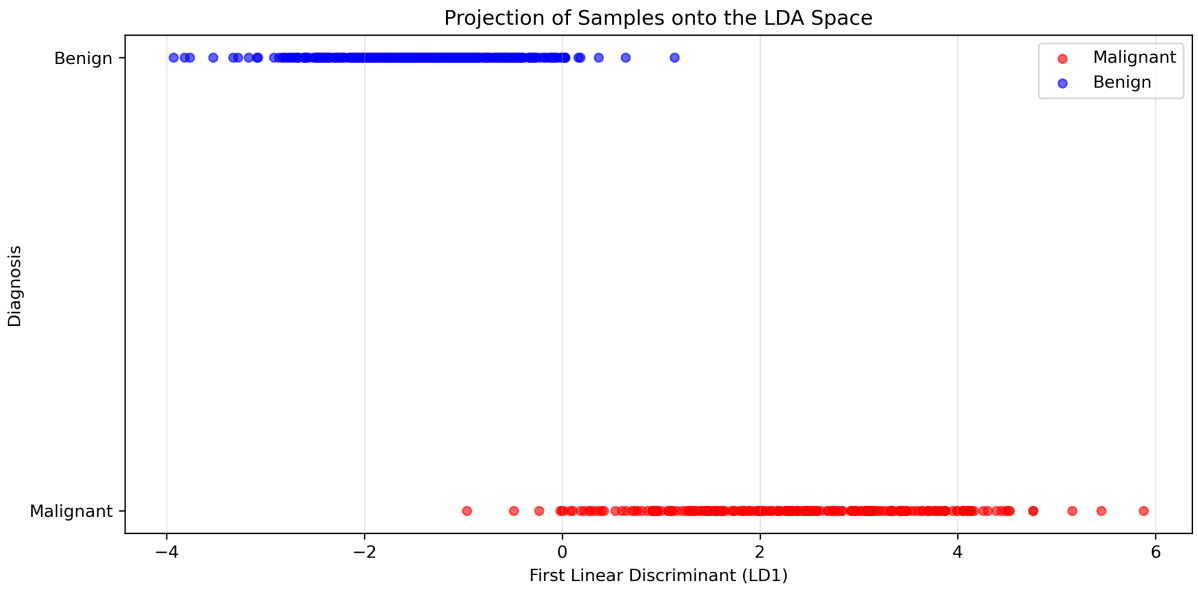
6.3.1. Αποτελέσματα και ερμηνεία. Η εφαρμογή της LDA πραγματοποιήθηκε στα 569 δείγματα του dataset, καθένα από τα οποία περιγράφεται από 30 αριθμητικά χαρακτηριστικά και ανήκει σε μία από τις δύο κατηγορίες διάγνωσης, 357 καλοήθεις και 212 κακοήθεις όγκους. Κατά την εφαρμογή αυτή, τα δεδομένα μετασχηματίστηκαν από τον αρχικό χώρο των 30 χαρακτηριστικών σε μία μόνο διακριτική συνιστώσα. Αυτό ήταν αναμενόμενο εξάλου, καθώς το dataset περιλαμβάνει δύο κατηγορίες διάγνωσης και η LDA μπορεί να παράγει το πολύ $k - 1$ διακριτικές συνιστώσες, όπου k ο αριθμός των κατηγοριών.

Η κατανομή των δειγμάτων στην πρώτη διακριτική συνιστώσα (LD1) παρουσιάζεται στο Σχήμα 3. Τα δείγματα καλοήθων όγκων φαίνεται πως συγκεντρώνονται κυρίως σε αρνητικές τιμές της LD1, ενώ τα δείγματα κακοήθων όγκων εμφανίζονται κυρίως σε θετικές τιμές. Η περιορισμένη επικάλυψη των δύο κατανομών δηλώνει ότι η LDA επιτυγχάνει αρκετά καλό διαχωρισμό των δύο κατηγοριών, αν και ο διαχωρισμός δεν είναι απόλυτος. Το ίδιο συμπέρασμα απεικονίζεται και στο Σχήμα 4, για μεγαλύτερη αμεσότητα.

Πέρα από τη μείωση διαστάσεων, η LDA εφαρμόζεται και ως ταξινομητής, με στόχο την πρόβλεψη της διάγνωσης κάθε δείγματος. Για τον σκοπό αυτό, το dataset διαχωρίζεται σε σύνολο εκπαίδευσης (80%) και σύνολο ελέγχου (20%), διατηρώντας ταυτόχρονα την αναλογία των δύο κατηγοριών σε κάθε σύνολο. Το μοντέλο εκπαιδεύεται στα δεδομένα



Σχήμα 3: Κατανομή των δειγμάτων καλοήθων και κακοήθων όγκων στην πρώτη διακριτική συνιστώσα (LD1) της LDA.



Σχήμα 4: Προβολή των δειγμάτων καλοήθων και κακοήθων όγκων στην πρώτη διακριτική συνιστώσα (LD1) της LDA.

εκπαίδευσης, αφού προηγηθεί τυποποίηση των χαρακτηριστικών, και έπειτα αξιολογείται στα δείγματα ελέγχου που δεν χρησιμοποιήθηκαν κατά την εκπαίδευση.

Πίνακας 2: Αποτελέσματα ταξινόμησης με τη μέθοδο LDA

Κατηγορία	Precision	Recall	F1-score	Πλήθος
Κακοήθεις	0.9744	0.9048	0.9383	42
Καλοήθεις	0.9467	0.9861	0.9660	72
Macro average	0.9605	0.9454	0.9521	114
Weighted average	0.9569	0.9561	0.9558	114
Συνολική ακρίβεια		0.9561		114

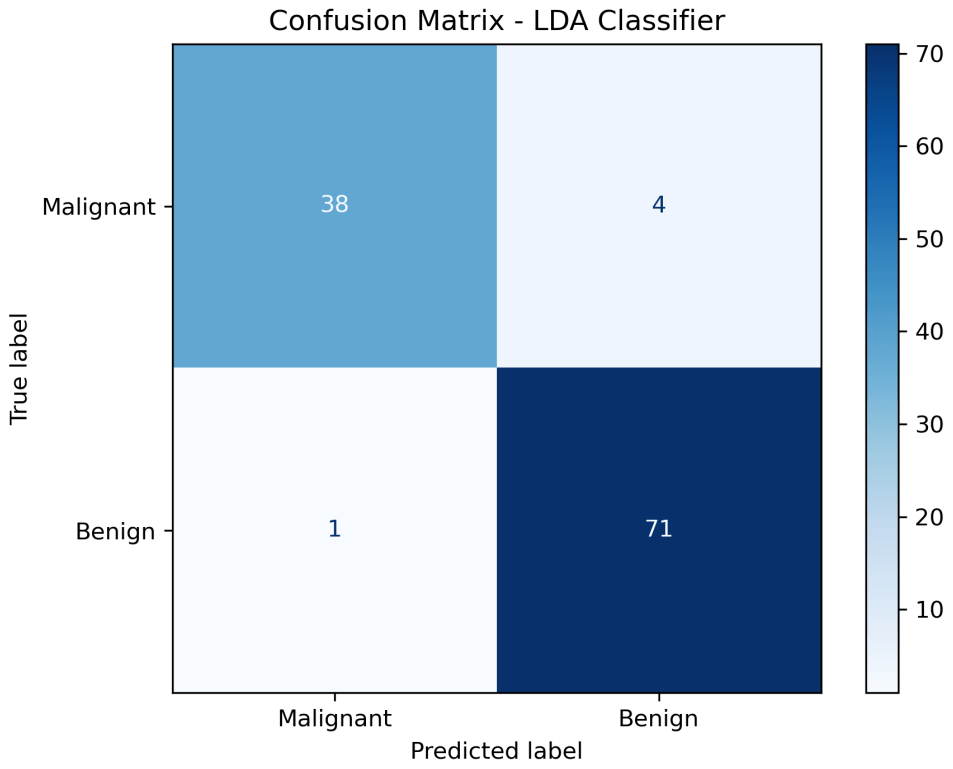
Η συνολική ακρίβεια ταξινόμησης ανέρχεται σε 95,61%, ενώ το σταθμισμένο F1-score είναι 95,58%, αποδεικνύοντας έτσι υψηλή απόδοση του μοντέλου τόσο ως προς την ορθότητα των προβλέψεων όσο και ως προς τον συνδυασμό precision, δηλαδή το ποσοστό των προβεβλεμένων δειγμάτων που όντως ανήκει στην κατηγορία που τοποθετήθηκε, και recall, δηλαδή το ποσοστό των δειγμάτων μιας κατηγορίας που ταξινομήθηκε σωστά. Επιπλέον, η διαφορά μεταξύ macro και weighted averages είναι γενικώς μικρή, γεγονός που υποδηλώνει ότι η συνολική εικόνα της απόδοσης δεν μεταβάλλεται σημαντικά όταν λαμβάνεται υπόψη η διαφορετική συχνότητα των δύο κατηγοριών. Ωστόσο, η χαμηλότερη ανάκληση για τους κακοήθεις όγκους δείχνει ότι ορισμένες κακοήθεις περιπτώσεις δεν εντοπίζονται, στοιχείο που πρέπει να λαμβάνεται υπόψη κατά την ερμηνεία των αποτελεσμάτων.

Μέσω του πίνακα σύγχυσης στο Σχήμα 5 παρατηρείται ότι ο ταξινομητής αναγνωρίζει σωστά τη συντριπτική πλειονότητα των καλοήθων όγκων, καθώς μόνο ένα δείγμα αυτής της κατηγορίας ταξινομείται λανθασμένα ως κακοήθες. Αντίθετα, τέσσερις κακοήθεις περιπτώσεις ταξινομούνται ως καλοήθεις, γεγονός που εξηγεί τη χαμηλότερη τιμή ανάκλησης (*recall*) για την κατηγορία των κακοήθων όγκων. Το εύρημα αυτό αναδεικνύει ότι η υψηλή συνολική ακρίβεια δεν συνεπάγεται εξίσου αποτελεσματική αναγνώριση όλων των κατηγοριών. Ωστόσο, στη συγκεκριμένη εφαρμογή, η μη αναγνώριση κακοήθων περιπτώσεων αποτελεί σημαντικό περιορισμό, καθώς οδηγεί σε εσφαλμένη εκτίμηση της διάγνωσης.

7. Συμπεράσματα και σύγκριση μεθόδων

Η PCA και η LDA αποτελούν δύο γραμμικές μεθόδους μείωσης διαστάσεων, οι οποίες διαφέρουν ως προς τον στόχο τους και τον τρόπο με τον οποίο αξιοποιούν τα δεδομένα. Η βασική τους διαφορά έγγυται στο γεγονός ότι η PCA επιδιώκει να διατηρήσει όσο το δυνατόν μεγαλύτερο μέρος της συνολικής διακύμανσης, χωρίς να λαμβάνει υπόψη τις κατηγορίες στις οποίες ανήκουν οι παρατηρήσεις, ενώ η LDA αξιοποιεί τις γνωστές ετικέτες αναζητώντας κατευθύνσεις που μεγιστοποιούν τον διαχωρισμό τους.

Ωστόσο, στην πρακτική εφαρμογή της PCA στο σύνολο δεδομένων Breast Cancer Wisconsin, η επικάλυψη μεταξύ των διαγνώσεων που αναδείχθηκε μέσω της προβολής των δειγμάτων στις δύο πρώτες κύριες συνιστώσες υπογραμμίζει τον βασικό περιορισμό της PCA, η διατήρηση της συνολικής διακύμανσης δεν εξασφαλίζει ότι διατηρείται εξίσου αποτελεσματικά η πληροφορία που είναι χρήσιμη για τον διαχωρισμό των κατηγοριών. Αντίθετα, η LDA εμφάνισε, μέσω της κατανομής των δειγμάτων στη νέα διάσταση, περιορισμένη επικάλυψη, δηλώνοντας αποτελεσματικότερο διαχωρισμό των δύο κατηγοριών.



Σχήμα 5: Πίνακας σύγχυσης του ταξινομητή LDA στο σύνολο ελέγχου.

Συμπερασματικά, η PCA είναι καταλληλότερη όταν ζητούμενο είναι η συμπίεση, η οπτικοποίηση ή η απλοποίηση ενός συνόλου δεδομένων χωρίς να είναι απαραίτητη η γνώση των κατηγοριών του. Αντίστοιχα, η LDA είναι προτιμητέα όταν υπάρχουν προκαθορισμένες κατηγορίες και επιδιώκεται η ταξινόμηση νέων παρατηρήσεων. Επομένως, η επιλογή μεταξύ των δύο μεθόδων εξαρτάται από τον σκοπό της ανάλυσης, καθώς η PCA προσφέρει μια συμπαγή αναπαράσταση της συνολικής πληροφορίας των δεδομένων ενώ η LDA εστιάζει κυρίως στην πληροφορία που διαφοροποιεί τις κατηγορίες.

8. Βιβλιογραφία

Αναφορές

[1] François de Ryckel. Chapter 12: Case study -- wisconsin breast cancer. *Machine Learning with R*, February 2019. Published February 23, 2019. Accessed October 13, 2026.

[2] Felipe L. Gewers, Gustavo R. Ferreira, Henrique F. de Arruda, Filipi N. Silva, Cesar H. Comin, Diego R. Amancio, and Luciano da F. Costa. Principal component analysis: A natural approach to data exploration. *ACM Computing Surveys*, 54(4):70:1--70:34, 2021.

[3] Ian T. Jolliffe and Jorge Cadima. Principal component analysis: a review and recent developments. *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*, 374(2065):20150202, 2016.

[4] Scikit-learn developers. Decomposing signals in components (matrix factorization problems). https://sklearn.org/stable/modules/decomposition.html. Scikit-learn Documentation, accessed October 13, 2026.

[5] Scikit-learn developers. Linear and quadratic discriminant analysis. https://scikit-learn.org/stable/modules/lda_qda.html. Scikit-learn Documentation, accessed October 20, 2026.

[6] Scikit-learn developers. Linear Discriminant Analysis. Official API documentation, accessed October 20, 2026.

[7] Scikit-learn developers. sklearn.datasets.load_breast_cancer. https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_breast_cancer.html. Scikit-learn Documentation, accessed October 19, 2026.

[8] Alaa Tharwat, Tarek Gaber, Abdelhameed Ibrahim, and Aboul Ella Hassanien. Linear discriminant analysis: A detailed tutorial. *AI Communications*, 30(2):169--190, 2017.

[9] William Wolberg, Olvi Mangasarian, Nick Street, and W. Street. Breast cancer wisconsin (diagnostic). UCI Machine Learning Repository, 1993.

9. Παράρτημα

9.1. Παράρτημα Α: Εναλλακτική προσέγγιση μέσω SVD

Εκτός από την ανάλυση του πίνακα συνδιακύμανσης, η PCA μπορεί να υλοποιηθεί μέσω της ανάλυσης ιδιαζουσών τιμών (*Singular Value Decomposition - SVD*). Η προσέγγιση αυτή μπορεί να είναι υπολογιστικά αποδοτικότερη, καθώς δεν απαιτεί τον ρητό σχηματισμό του πίνακα συνδιακύμανσης.

Με την SVD, ο πίνακας των κεντραρισμένων δεδομένων γράφεται ως:

$$X_c = U\Sigma V^T,$$

όπου οι στήλες των U και V είναι, αντίστοιχα, τα αριστερά και τα δεξιά ιδιάζοντα διανύσματα, ενώ ο Σ είναι διαγώνιος πίνακας που περιέχει τις ιδιάζουσες τιμές σ_j.

Τα δεξιά ιδιάζοντα διανύσματα, δηλαδή οι στήλες του V, καθορίζουν τις κύριες διευθύνσεις της PCA. Οι ιδιοτιμές λ_j του πίνακα συνδιακύμανσης συνδέονται με τις αντίστοιχες ιδιάζουσες τιμές μέσω της σχέσης:

$$\lambda_j = \frac{\sigma_j^2}{n-1},$$

όπου n είναι ο αριθμός των παρατηρήσεων, με την προϋπόθεση ότι ο πίνακας συνδιακύμανσης υπολογίζεται με παρονομαστή $n-1$.

9.2. Παράρτημα Β: Κώδικας υλοποίησης PCA σε Python

```python
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

from sklearn.datasets import load_breast_cancer
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA

data = load_breast_cancer(as_frame=True)

X = data.data

# Labels: 0-> Malignant , 1-> Benign
y = data.target

print("Dataset dimensions:", X.shape)
print("Top 5 instances:")
display(X.head())

print("\nDiagnosis distribution:")
print(y.value_counts().rename(index={
    0: "Malignant",
    1: "Benign"
}))

```

```
# Standardize the features
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

# Apply PCA
pca = PCA()
X_pca = pca.fit_transform(X_scaled)

print("Original dimensions:", X_scaled.shape)
print("Dimensions after PCA:", X_pca.shape)

explained_variance = pca.explained_variance_ratio_
cumulative_variance = np.cumsum(explained_variance)

variance_table = pd.DataFrame({
    "Principal Component": np.arange(1, len(explained_variance) + 1),
    "Explained Variance (%)": explained_variance * 100,
    "Cumulative Explained Variance (%)": cumulative_variance * 100
})

display(variance_table.round(2))

print(
    "Number of components needed to explain at least 95% of the
       variance:",
    np.argmax(cumulative_variance >= 0.95) + 1
)

plt.figure(figsize=(9, 5))

plt.plot(
    range(1, len(cumulative_variance) + 1),
    cumulative_variance * 100,
    marker="o"
)

plt.axhline(y=95, linestyle="--", label="95% variance")

plt.xlabel("Number of Principal Components")
plt.ylabel("Cumulative Explained Variance (%)")
plt.title("PCA: Cumulative Explained Variance")
plt.grid(True, alpha=0.3)
plt.legend()
plt.tight_layout()
plt.savefig(r"C:/Users/ak221/Downloads/pca_cumulative_variance.png",
            dpi=300, bbox_inches="tight")
plt.show()

plt.figure(figsize=(9, 6))

colors = {0: "red", 1: "blue"}
```

```
labels = {0: "Malignant", 1: "Benign"}

for diagnosis in [0, 1]:
    mask = (y == diagnosis)

    plt.scatter(
        X_pca[mask, 0],
        X_pca[mask, 1],
        c=colors[diagnosis],
        label=labels[diagnosis],
        alpha=0.7
    )

plt.xlabel("First Principal Component (PC1)")
plt.ylabel("Second Principal Component (PC2)")
plt.title("PCA of the Breast Cancer Wisconsin Dataset")
plt.legend()
plt.grid(True, alpha=0.3)
plt.tight_layout()
plt.savefig(r"C:/Users/ak221/Downloads/pca_scatter.png",
            dpi=300, bbox_inches="tight")
plt.show()

# Apply PCA with the selected number of components
pca_reduced = PCA(n_components=10)
X_pca_reduced = pca_reduced.fit_transform(X_scaled)

print("Original dimensions:", X_scaled.shape)
print("Reduced dimensions:", X_pca_reduced.shape)

# Calculation
retained_variance = pca_reduced.explained_variance_ratio_.sum()

print(
    "Cumulative explained variance (%):",
    round(retained_variance * 100, 2)
)
```

Listing 1: PCA implementation using Python

9.3. Παράρτημα Γ: Κώδικας υλοποίησης LDA σε Python

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

from sklearn.datasets import load_breast_cancer
from sklearn.preprocessing import StandardScaler
from sklearn.discriminant_analysis import LinearDiscriminantAnalysis
from sklearn.model_selection import train_test_split
from sklearn.pipeline import make_pipeline
```

```
from sklearn.metrics import (
    accuracy_score,
    classification_report,
    confusion_matrix,
    ConfusionMatrixDisplay,
    roc_auc_score
)

# Load the dataset
data = load_breast_cancer(as_frame=True)

X = data.data

# Labels: 0 -> Malignant, 1 -> Benign
y = data.target

print("Dataset dimensions:", X.shape)

print("Top 5 instances:")
display(X.head())

print("\nDiagnosis distribution:")
print(
    y.value_counts()
     .rename(index={0: "Malignant", 1: "Benign"})
)

# Standardize the features
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

print("\nDimensions after standardization:", X_scaled.shape)

# Apply LDA for dimensionality reduction
lda = LinearDiscriminantAnalysis(n_components=1)

X_lda = lda.fit_transform(X_scaled, y)

print("Original dimensions:", X_scaled.shape)
print("Dimensions after LDA:", X_lda.shape)

print("\nNumber of discriminant components:", X_lda.shape[1])

# Plot the distribution of the first discriminant component
plt.figure(figsize=(9, 6))

colors = {0: "red", 1: "blue"}
labels = {0: "Malignant", 1: "Benign"}

for diagnosis in [0, 1]:
    mask = (y.to_numpy() == diagnosis)
```

```
61
62      plt.hist(
63          X_lda[mask, 0],
64          bins=25,
65          alpha=0.55,
66          color=colors[diagnosis],
67          label=labels[diagnosis],
68          density=True
69      )
70
71  plt.xlabel("First Linear Discriminant (LD1)")
72  plt.ylabel("Density")
73  plt.title("LDA of the Breast Cancer Wisconsin Dataset")
74  plt.legend()
75  plt.grid(True, alpha=0.3)
76  plt.tight_layout()
77
78  plt.savefig(
79      r"C:/Users/ak221/Downloads/lda_histogram.png",
80      dpi=300,
81      bbox_inches="tight"
82  )
83
84  plt.show()
85
86  # Plot individual samples in the one-dimensional LDA space
87  plt.figure(figsize=(10, 5))
88
89  colors = {0: "red", 1: "blue"}
90  labels = {0: "Malignant", 1: "Benign"}
91  y_positions = {0: 0, 1: 1}
92
93  for diagnosis in [0, 1]:
94      mask = (y.to_numpy() == diagnosis)
95
96      plt.scatter(
97          X_lda[mask, 0],
98          np.full(mask.sum(), y_positions[diagnosis]),
99          c=colors[diagnosis],
100         label=labels[diagnosis],
101         alpha=0.6,
102         s=25
103     )
104
105 plt.yticks([0, 1], ["Malignant", "Benign"])
106 plt.xlabel("First Linear Discriminant (LD1)")
107 plt.ylabel("Diagnosis")
108 plt.title("Projection of Samples onto the LDA Space")
109 plt.legend()
110 plt.grid(True, axis="x", alpha=0.3)
111 plt.tight_layout()
```

```
112
113 plt.savefig(
114     r"C:/Users/ak221/Downloads/lda_projection.png",
115     dpi=300,
116     bbox_inches="tight"
117 )
118
119 plt.show()
120
121 # Create a table with the LDA-transformed data
122 lda_table = pd.DataFrame({
123     "LD1": X_lda[:, 0],
124     "Diagnosis": y.map({0: "Malignant", 1: "Benign"}).to_numpy()
125 })
126
127 print("First 10 samples in the LDA space:")
128 display(lda_table.head(10).round(4))
129
130 X_train, X_test, y_train, y_test = train_test_split(
131     X,
132     y,
133     test_size=0.20,
134     random_state=42,
135     stratify=y
136 )
137
138 print("Training set dimensions:", X_train.shape)
139 print("Test set dimensions:", X_test.shape)
140
141 # Standardization + LDA classifier
142 lda_classifier = make_pipeline(
143     StandardScaler(),
144     LinearDiscriminantAnalysis()
145 )
146
147 # Train
148 lda_classifier.fit(X_train, y_train)
149
150 # Predict the test samples
151 y_pred = lda_classifier.predict(X_test)
152
153 print("\nModel training completed.")
154
155 # Classification metrics
156 accuracy = accuracy_score(y_test, y_pred)
157
158 print("Accuracy:", round(accuracy, 4))
159 print("\nClassification report:")
160
161 print(
162     classification_report(
```

```
        y_test,
        y_pred,
        labels=[0, 1],
        target_names=["Malignant", "Benign"],
        digits=4,
        zero_division=0
    )
)

# Confusion matrix
cm = confusion_matrix(
    y_test,
    y_pred,
    labels=[0, 1]
)

disp = ConfusionMatrixDisplay(
    confusion_matrix=cm,
    display_labels=["Malignant", "Benign"]
)

disp.plot(cmap="Blues", values_format="d")

plt.title("Confusion Matrix - LDA Classifier")
plt.tight_layout()

plt.savefig(
    r"C:/Users/ak221/Downloads/lda_confusion_matrix.png",
    dpi=300,
    bbox_inches="tight"
)

plt.show()
```

Listing 2: LDA implementation using Python